

知能プログラミング演習 I

## 第 7 回: 畳み込みニューラルネットワーク II

---

梅津 佑太

2 号館 404A: umezu.yuta@nitech.ac.jp

# 課題のダウンロード

前回作ったディレクトリに移動して今日の課題のダウンロードと解凍

**step1:** `cd ./DLL`

**step2:** `wget http://www-als.ics.nitech.ac.jp/~umezu/Lec7.zip`

**step3:** `unzip Lec7.zip`

- ✓ まだ DLL のフォルダを作っていない人は, step1 の前に  
`mkdir -p DLL`  
でフォルダを作成する

講義ノート更新しました.

## 1. 畳み込みニューラルネットワークの逆伝播

## 前回の復習

畳み込みニューラルネットワークの構成要素:

- 畳み込み層: 入力  $\mathbb{R}^{d \times d \times K} \ni Z \mapsto Z' \in \mathbb{R}^{d' \times d' \times M}$ :

$$u_{ijm} = \langle W_m, Z_{ij} \rangle + b_m \mapsto z'_{ijm} = f(u_{ijm})$$

- プーリング層: 入力  $\mathbb{R}^{d \times d \times K} \ni Z \mapsto Z' \in \mathbb{R}^{d' \times d' \times K}$ :

$$u_{ijk} = \langle W_{ijk}, Z_k \rangle \mapsto z'_{ijk} = u_{ijk}$$

✓  $W_{ijk} \in \mathbb{R}^{d \times d}$  の作り方は後述

- 全結合層: 入力  $\mathbb{R}^{d \times d \times K} \ni Z \mapsto Z' \in \mathbb{R}^{d'}$ :

$$u_i = \langle W_i, Z \rangle + b_i \mapsto z'_i = f(u_i)$$

ただし,  $\langle \cdot, \cdot \rangle$  はテンソルの内積

$$\langle A, B \rangle = \sum_{ijk} a_{ijk} b_{ijk}, \quad A, B \in \mathbb{R}^{d \times d \times K}$$

$$\langle A, B \rangle = \sum_{ij} a_{ij} b_{ij} = \text{tr}(A^\top B), \quad A, B \in \mathbb{R}^{d \times d}$$

- c.f., これまでの逆伝播: 適当なサイズの行列  $W_{r+1}$  ( $r+1$  層目のパラメータ) と  $\delta_{r+1}$  を用いて,

$$\begin{aligned}\delta_r &= W_{r+1}^\top \delta_{r+1} \odot \nabla f(\mathbf{u}_r) \\ \Rightarrow \delta_{r,j} &= \tilde{\mathbf{w}}_{r+1,j}^\top \delta_{r+1} \nabla f(u_{r,j}) = \langle \tilde{\mathbf{w}}_{r+1,j}, \delta_{r+1} \rangle \nabla f(u_{r,j})\end{aligned}$$

とかけた<sup>1</sup>. つまり,  $\delta_r$  は “ $r+1$  層目のパラメータ  $\mathbf{w}_{r+1,j}$  と誤差  $\delta_{r+1}$  に  $r$  層目の勾配  $\nabla f(u_{r,j})$  の積を適当な順番に並べたもの”

- 畳み込みニューラルネットワークの場合も適当なサイズのパラメータ  $W_{r+1,ijk}$  や  $\delta_{r+1}$ ,  $\nabla f(u_{r,ijk})$  を用いて

$$\delta_{r,ijk} = \langle W_{r+1,ijk}, \delta_{r+1} \rangle \nabla f(u_{r,ijk})$$

と書くことができる.

---

<sup>1</sup>  $\tilde{\mathbf{w}}_{r+1,j}$  は  $W_{r+1}$  の第  $j$  列ベクトル

## 逆伝播: 全結合層 I

全結合層:  $Z_r \in \mathbb{R}^{d \times d \times K} \mapsto Z_{r+1} = f(U_r) \in \mathbb{R}^{d'}$

- パラメータ  $W_r = (W_{r,1}, \dots, W_{r,d'}) \in \mathbb{R}^{d \times d \times K \times d'}$  および  $b_r = (b_{r,1}, \dots, b_{r,d'})^\top \in \mathbb{R}^{d'}$  を用いて,

$$u_{r,i} = \sum_{k=1}^K \sum_{j=1}^{d'} w_{r,ijk} z_{r,ijk} + b_{r,i} = \langle W_{r,i}, Z_r \rangle + b_{r,i}$$

- これまで通り,  $Z_{r+1}$  が出力層なら, 適当な誤差関数  $E$  と活性化関数  $f$  に対して

$$\delta_r = \frac{\partial E}{\partial \mathbf{u}_r} = f(\mathbf{u}_r) - \mathbf{y}$$

となる. ただし,  $\mathbf{y}$  は観測データの出力 (e.g., 多クラス分類なら 1-of- $K$  表記のベクトル)

- $Z_{r+1}$  が出力層でない場合, 適当な大きさの行列  $W_{r+1}$  に対して,

$$u_{r+1,i} = \mathbf{w}_{r+1,i}^\top Z_{r+1} + b_{r+1,i} = \mathbf{w}_{r+1,i}^\top f(U_r) + b_{r+1,i}$$

なので,

$$\begin{aligned}\delta_{r,i} &= \frac{\partial E}{\partial u_{r,i}} = \sum_j \frac{\partial E}{\partial u_{r+1,j}} \frac{\partial u_{r+1,j}}{\partial u_{r,i}} = \sum_j \delta_{r+1,j} \frac{\partial \mathbf{w}_{r+1,j}^\top f(U_r)}{\partial u_{r,i}} \\ &= \sum_j \delta_{r+1,j} w_{r+1,ij} \nabla f(u_{r,i}) = \tilde{\mathbf{w}}_{r+1,i}^\top \delta_{r+1} \nabla f(u_{r,i}) \\ \Rightarrow \delta_r &= W_{r+1}^\top \delta_{r+1} \odot \nabla f(\mathbf{u}_r)\end{aligned}$$

## 逆伝播: プーリング層 I

プーリング層:  $Z_r \in \mathbb{R}^{d \times d \times K} \mapsto Z_{r+1} \in \mathbb{R}^{d' \times d' \times K}$ . フィルタサイズ  $s$ , ストライド数  $\beta$  に対して,  $d' = (d - s)/\beta + 1$

- $P_{ij} = \{(\beta(i-1) + p, \beta(j-1) + q, k) \mid p, q = 1, \dots, s\}$  として,  $W_{r,ij} = (w_{r,ij,pqk})_{ij} \in \mathbb{R}^{d \times d}$  を

$$(\text{max プーリング}) \quad w_{r,ij,pqk} = \begin{cases} 1 & (p, q) = \arg \max_{(s,t) \in P_{ij}} Z_{r,stk} \\ 0 & \text{その他} \end{cases}$$

$$(\text{average プーリング}) \quad w_{r,ij,pqk} = 1/s^2$$

とすれば,  $i, j = 1, \dots, d', k = 1, \dots, K$  に対して

$$Z_{r+1,ijk} = u_{r,ijk} = \langle W_{r,ij}, Z_{r,k} \rangle$$

- このとき, プーリングの写像  $g$  は恒等写像と解釈する.

$$\nabla g(u_{r,ijk}) = \frac{\partial g(u_{r,pqr})}{\partial u_{r,pqr}} \Big|_{u=u_{r,ijk}} = \begin{cases} 1 & i = p, j = q, k = r \\ 0 & \text{その他} \end{cases}$$



## 逆伝播: プーリング層 II

適当なサイズの  $W_{r+1}$ ,  $b_{r+1}$  に対して,

$$u_{r+1,ijm} = \langle W_{r+1,m}, Z_{r+1,ij} \rangle + b_{r+1,m} = \langle W_{r+1,m}, U_{r,ij} \rangle + b_{r+1,m}$$

とする<sup>2</sup>.  $U_{r,ijk} = (u_{r,\beta'(i-1)+p,\beta'(j-1)+q,k})_{p,q}$  に対して,  $U_{r,ij} = (U_{r,ijk})_k$  を 3 次元配列とすれば, 誤差  $\delta_{r,ijk}$  は

$$\begin{aligned}\delta_{r,ijk} &= \frac{\partial E}{\partial u_{r,ijk}} = \sum_{s,t,l} \frac{\partial E}{\partial u_{r+1,sti}} \frac{\partial u_{r+1,sti}}{\partial u_{r,ijk}} \\ &= \sum_{s,t,l} \delta_{r+1,sti} \frac{\partial \langle W_{r+1,l}, U_{r,st} \rangle}{\partial u_{r,ijk}} = \sum_{s,t,l} \delta_{r+1,sti} w_{r+1,i-\beta'(s-1),j-\beta'(t-1),k,l}\end{aligned}$$

---

<sup>2</sup> $r+2$  層目が全結合層ならば,  $u_{r+1,m} = \langle W_{r+1,m}, U_r \rangle + b_{r+1,m}$  となる.

$$\delta_{r,ijk} = \sum_{s,t,l} \delta_{r+1,sl} w_{r+1,i-\beta'(s-1),j-\beta'(t-1),k,l}$$

は,  $\delta_{r+1} = (\delta_{r+1,sl})_{s,t,l}$ ,  $W_{r+1,ijk} = (w_{r+1,i-\beta'(s-1),j-\beta'(t-1),k,l})_{s,t,l}$  とすれば,

$$\delta_{r,ijk} = \langle \delta_{r+1}, W_{r+1,ijk} \rangle$$

とかける. したがって,  $\delta = (\delta_{r,ijk})_{i,j,k}$  とすれば, これがプーリング層の誤差となる.

畳み込み層: パディング数  $\alpha$  で畳み込んだ後の入力を  $Z_r \in \mathbb{R}^{d \times d \times K}$  として<sup>3</sup>,  $Z_r \mapsto Z_{r+1} \in \mathbb{R}^{d' \times d' \times M}$ . ただし, フィルタサイズ  $H$ , スライド数  $\beta$  に対して,  $d' = (d - H)/\beta + 1$ .

- パラメータ  $W_r = (W_{r,1}, \dots, W_{r,d'}) \in \mathbb{R}^{d \times d \times K \times M}$  および  $b_r = (b_{r,1}, \dots, b_{r,M})^\top \in \mathbb{R}^M$  を用いて,

$$\begin{aligned} u_{r,ijm} &= \sum_{k=1}^K \sum_{p,q=1}^{d'} W_{r,pqkm} Z_{r,\beta(i-1)+p,\beta(j-1)+q,k} + b_{r,m} \\ &= \langle W_{r,m}, Z_{r,ij} \rangle + b_{r,m} \end{aligned}$$

ただし,  $Z_{r,ijk} = (Z_{r,ij,\beta(i-1)+p,\beta(j-1)+q,k})_{p,q}$  に対して,  
 $Z_{r,ij} = (Z_{r,ij1}, \dots, Z_{r,ijK}) \in \mathbb{R}^{H \times H \times K}$

---

<sup>3</sup>  $X \in \mathbb{R}^{p \times p}$  をパディング数  $\alpha$  で畳み込むと  $d = p + 2\alpha$  となる.

$$u_{r,ijm} = \langle W_{r,m}, Z_{r,ij} \rangle + b_{r,m}$$

が、プーリング層の順伝播と一致することに注意すれば、適当な  $\delta_{r+1} = (\delta_{r+1, stl})_{s,t,l}$ ,  $W_{r+1,ijk} = (w_{r+1, i-\beta'(s-1), j-\beta'(t-1), k, l})_{s,t,l}$  を用いて,

$$\delta_{r,ijk} = \langle \delta_{r+1}, W_{r+1,ijk} \rangle$$

とかける. したがって,  $\delta = (\delta_{r,ijk})_{i,j,k}$  とすれば, これが畳み込み層の誤差となる.

## パラメータの更新ルール

$\delta_r$  が計算できると、パラメータの更新ルールを求めることができる：つまり、合成関数の微分を用いて、

$$\begin{aligned}\frac{\partial E}{\partial w_{r,pqkm}} &= \sum_{s,t=1}^H \frac{\partial E}{\partial u_{r,stm}} \frac{\partial u_{r,stm}}{\partial w_{r,pqkm}} = \sum_{s,t=1}^H \delta_{r,stm} Z_{r,\beta(s-1)+p,\beta(t-1)+q,k} \\ \frac{\partial E}{\partial b_{r,m}} &= \sum_{s,t=1}^H \frac{\partial E}{\partial u_{r,stm}} \frac{\partial u_{r,stm}}{\partial b_{r,m}} = \sum_{s,t=1}^H \delta_{r,stm}\end{aligned}$$

より、

$$\frac{\partial E}{\partial w_{r,m}} = \sum_{s,t=1}^H \delta_{r,stm} Z_{r,st} \quad \text{および} \quad \frac{\partial E}{\partial b_r} = \sum_{s,t=1}^H \delta_{r,st}$$

となる。これを用いて、確率的勾配降下法や Adam のアルゴリズムを実装すれば良い。